Pr. I. HAMZAOUI / Filière : CCN-2
Module : Machine Learning
Année universitaire 2025/2026

Travaux Pratiques N°8

Nom et prénom : ……

Objectifs du TP : L'objectif de ce TP est de mettre en pratique un pipeline complet de clustering hiérarchique :

- Préparation et standardisation des données
- Construction d'un dendrogramme
- Choix visuel de K via une coupure horizontale
- Vérification du choix via les métriques
- Application finale du modèle
- Interprétation des clusters

Livrables à rendre : Complétez ce document manuscritement par le travail demandé.

Données : Vous disposez du fichier clustering_clients_TP8.csv. Le dataset contient trois indicateurs comportementaux typiques en marketing :

- **DaysSinceLastPurchase** : nombre de jours depuis le dernier achat
- **YearlyOrders** : nombre total d'achats sur l'année
- **YearlySpending_kDH** : montant dépensé sur l'année (en milliers de DH)

1) Exécutez le code ci-dessous et visualisez les données brutes des clients en 3D

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import AgglomerativeClustering
from sklearn.metrics import (
    silhouette_score,
    davies_bouldin_score,
    calinski_harabasz_score,
)
from scipy.cluster.hierarchy import linkage, dendrogram
```

```
df = pd.read_csv("clustering_clients_TP8.csv")
```

```
fig = plt.figure(figsize=(8, 6))
ax = fig.add_subplot(111, projection="3d")
ax.scatter(
    df["DaysSinceLastPurchase"],
    df["YearlyOrders"],
    df["YearlySpending_kDH"],
    s=10,
    alpha=0.6)
ax.set_xlabel("DaysSinceLastPurchase")
ax.set_ylabel("YearlyOrders")
ax.set_zlabel("YearlySpending_kDH")
ax.set_title("Données brutes clients (3D)")
plt.show()
```

2) **Exécutez d'abord la mise à l'échelle suivante dans une cellule. Puis, dans une nouvelle cellule, générez le dendrogramme (Ward)**

```
X = df[["DaysSinceLastPurchase", "YearlyOrders", "YearlySpending_kDH"]].values
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

```
Z =
# Affichage du dendrogramme dans une figure de taille (10,4)
```

3) **À partir du dendrogramme ci-dessous, proposez un nombre de clusters qui vous paraît pertinent. Justifiez votre choix en traçant une coupe horizontale du dendrogramme.**

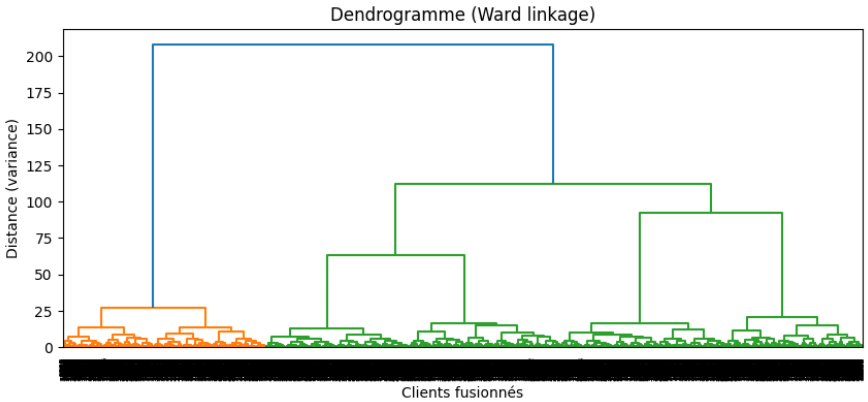

4) **Complétez le code ci-dessous**

```
k_range =                 # K de 2 à 10

# Listes vides pour stocker les scores
sil_scores = []
dbi_scores = []
ch_scores  = []

for k in k_range:
    # Créer le modèle AgglomerativeClustering en passant n_clusters et linkage
    agglom =




    # 2) Entraîner le modèle sur les données standardisées X_scaled
    labels =

    # Calculer les trois métriques de qualité du clustering
    sil =
    dbi =
    ch  =

    # Sauvegarder les scores dans les listes




    # Afficher les résultats pour cette valeur de K
    print(f"K = {k:2d} | Silhouette = {sil:.3f} | DBI = {dbi:.3f} | CH = {ch:.1f}")
```

5) **Exécutez le code ci-dessous pour tracer les courbes de Silhouette, DBI et CH en fonction de K. Le nombre de K que vous aviez proposé à partir du dendrogramme est-il cohérent avec ces résultats ? Justifiez votre réponse.**

```
plt.figure(figsize=(14, 4))

plt.subplot(1, 3, 1)
plt.plot(k_range, sil_scores, marker="o")
plt.xlabel("K")
plt.ylabel("Silhouette")
plt.title("Silhouette vs K (plus haut = mieux)")

plt.subplot(1, 3, 2)
plt.plot(k_range, dbi_scores, marker="o")
plt.xlabel("K")
plt.ylabel("Davies-Bouldin")
plt.title("DBI vs K (plus bas = mieux)")

plt.subplot(1, 3, 3)
plt.plot(k_range, ch_scores, marker="o")
plt.xlabel("K")
plt.ylabel("Calinski-Harabasz")
plt.title("CH vs K (plus haut = mieux)")

plt.tight_layout()
plt.show()
```

Réponse :

6) **Complétez le code suivant**

```
# Modèle final AgglomerativeClustering avec le "meilleur" K
# Indiquez ici la valeur de K retenue
best_k =

# Créez le modèle de clustering hiérarchique




# Entraînez le modèle sur les données standardisées
labels_final =

# Ajoutez la colonne "Cluster" au DataFrame d'origine


# Affichez la taille de chaque cluster (ordonnée par numéro de cluster)
```

7) Ecrivez un code Python utilisant Matplotlib qui :

- ✓ crée une figure 3D ;
- ✓ trace un nuage de points où :l'axe **X** représente YearlySpending_kDH, l'axe **Y** représente YearlyOrders, l'axe **Z** représente DaysSinceLastPurchase.
- ✓ la couleur des points est déterminée par la colonne df["Cluster"] (un code couleur différent par cluster) ;
- ✓ choisit une taille de points raisonnable et une légère transparence pour mieux voir les superpositions ;
- ✓ ajoute les labels des axes et un titre ;
- ✓ affiche une **légende** indiquant clairement les numéros de clusters.

```
# Visualisation finale 3D des clusters
```

8) En exécutant le code suivant, remplissez le tableau ci-dessous.

```
# Profil moyen des clusters
cluster_profiles = (
    df.groupby("Cluster")
      .agg(
          DaysSinceLastPurchase=("DaysSinceLastPurchase", "mean"),
          YearlyOrders=("YearlyOrders", "mean"),
          YearlySpending_kDH=("YearlySpending_kDH", "mean"),
          Count=("Cluster", "size"),
      )
      .round(1)
)
print("\nProfils moyens des clusters :")
print(cluster_profiles)
```

Cluster	DaysSinceLastPurchase	YearlyOrders	YearlySpending_kDH	Count
0				
1				
2				
3				
4				

9) **À partir du tableau ci-dessus, interprétez les profils moyens des clusters et décrivez le type de clients représenté dans chaque groupe.**

Réponse :